

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Inteligencia Computacional y Optimización Metaheurística	2
1.	Efectividad de los Algoritmos Genéticos	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos	3
1.3.	Metodología y Análisis de la Literatura	4
1.4.	Conclusiones	5

Parte I

Introducción y Fundamentos

Parte II

Inteligencia Computacional y Optimización Metaheurística

Capítulo 1

Efectividad de los Algoritmos Genéticos en la Optimización de Problemas Complejos de Ingeniería

Autor: María Soledad Buri Camacho (maria.s.buri@unl.edu.ec)
Técnica asignada: Algoritmos Genéticos

1.1. Introducción

Este capítulo aborda formalmente el uso de los Algoritmos Genéticos (AG) para dar respuesta a la pregunta de investigación planteada: ¿Qué tan efectivos son los algoritmos genéticos en la optimización de problemas complejos de ingeniería?. Los algoritmos genéticos constituyen una categoría de algoritmos evolutivos y metaheurísticos inspirados en los mecanismos de selección natural y genética biológica, diseñados para realizar búsquedas eficientes en espacios de soluciones extensos, no lineales y altamente dimensionales [1, 2].

A diferencia de los métodos deterministas tradicionales basados en gradientes, los AG trabajan sobre poblaciones de soluciones candidatas denominadas cromosomas y no requieren información derivativa de la función objetivo, lo que permite abordar problemas complejos con discontinuidades, multimodalidad y múltiples restricciones de optimización [3, 4]. Estas características han convertido a los algoritmos genéticos en herramientas ampliamente utilizadas en aplicaciones de ingeniería relacionadas con diseño estructural, optimización industrial, planificación de producción, diseño electromagnético, control inteligente y optimización multiobjetivo [5, 6].

Las investigaciones recientes evidencian que los AG presentan una elevada capacidad de exploración global y robustez computacional frente a problemas NP-Hard, especialmente cuando se implementan estrategias híbridas y mecanismos adaptativos para mejorar el equilibrio entre exploración y explotación [7, 8]. Asimismo, múltiples estudios reportan mejoras significativas en precisión, estabilidad y reducción de costos computacionales en comparación con técnicas tradicionales de optimización [9, 10].

1.2. Fundamentos Teóricos

Los algoritmos genéticos pertenecen al área de la computación evolutiva y operan mediante la evolución iterativa de una población de soluciones candidatas hacia un óptimo global [?, ?]. Cada individuo dentro de la población representa una posible solución codificada mediante genes y cromosomas, cuya calidad es evaluada a través de una función de aptitud (*fitness function*) [11].

El proceso evolutivo se basa en tres operadores genéticos fundamentales: selección, cruce (*crossover*) y mutación. La selección favorece a los individuos con mejor aptitud, aumentando su probabilidad de reproducción. El operador de cruce combina información genética de dos individuos para generar nuevas soluciones, mientras que la mutación introduce diversidad aleatoria con el objetivo de evitar convergencia prematura hacia óptimos locales [12, 13].

Matemáticamente, el problema general de optimización resuelto por un algoritmo genético puede representarse mediante la minimización de una función objetivo sujeta a restricciones de desigualdad y límites de frontera, como se muestra en la Ecuación 1.1:

$$\text{Minimizar } f(x) \quad \text{sujeto a: } g_j(x) \leq 0, \quad x_l \leq x_i \leq x_u \quad (1.1)$$

donde x representa el conjunto de variables de diseño correspondientes a los genes del cromosoma, $g_j(x)$ representa las restricciones del problema y x_l, x_u corresponden a los límites inferiores y superiores de cada variable [14].

Los AG han demostrado elevada eficiencia en problemas multiobjetivo mediante el uso de optimización de Pareto, permitiendo obtener simultáneamente múltiples soluciones eficientes para problemas de ingeniería complejos [15]. Asimismo, los modelos híbridos han incorporado técnicas probabilísticas, operadores adaptativos y estrategias evolutivas avanzadas para incrementar la velocidad de convergencia y la estabilidad computacional [16, 17].

1.3. Metodología y Análisis de la Literatura

La presente investigación se desarrolló mediante una revisión bibliográfica sistemática de 20 artículos científicos indexados relacionados con aplicaciones de algoritmos genéticos en problemas complejos de ingeniería. Los estudios analizados abarcan áreas como optimización estructural, diseño electromagnético, planificación industrial, manufactura inteligente, aprendizaje automático y optimización multiobjetivo [18, 19].

A partir del análisis comparativo de la literatura científica, se identificaron las principales dimensiones técnicas asociadas al desempeño y efectividad de los algoritmos genéticos en entornos industriales y computacionales. Los resultados evidencian que los AG superan frecuentemente a los métodos convencionales en términos de robustez, estabilidad y capacidad de exploración global en espacios de búsqueda altamente complejos [9, 20].

Las investigaciones recientes muestran una tendencia hacia el desarrollo de algoritmos genéticos híbridos y autoadaptativos que incorporan modelos probabilísticos, redes bayesianas y operadores inteligentes para ajustar dinámicamente las tasas de mutación y cruce [7, 8]. Estas estrategias permiten mejorar significativamente la convergencia y evitar el estancamiento prematuro durante el proceso evolutivo.

En la Tabla 1.1 se resumen las dimensiones técnicas identificadas durante el análisis de la literatura especializada.

Tabla 1.1: Dimensiones de análisis en la efectividad de algoritmos genéticos.

Parámetro	Ventaja Tecnológica	Restricción
Búsqueda global	Capacidad de evitar óptimos locales	Alto costo computacional
Optimización multiobjetivo	Generación simultánea de soluciones eficientes	Dependencia de parametrización
Robustez	Resistencia frente a ruido e incertidumbre	Sensibilidad a operadores genéticos
Adaptabilidad	Aplicación en problemas no lineales complejos	Riesgo de convergencia prematura
Escalabilidad	Manejo de espacios de búsqueda extensos	Incremento del tiempo de procesamiento

Los resultados reportados en los artículos revisados confirman que los algoritmos genéticos poseen alta efectividad en problemas de ingeniería donde los métodos exactos presentan

limitaciones computacionales significativas [5, 6]. Además, las estrategias híbridas han demostrado mejoras importantes en precisión, estabilidad y velocidad de convergencia en aplicaciones industriales reales [3, 4].

1.4. Conclusiones

La revisión sistemática de los 20 documentos científicos analizados confirma que los algoritmos genéticos constituyen herramientas altamente efectivas para la optimización de problemas complejos de ingeniería. Su capacidad para explorar espacios de búsqueda extensos, manejar restricciones no lineales y generar soluciones cercanas al óptimo global permite resolver problemas computacionalmente complejos que resultan difíciles para métodos deterministas tradicionales.

Asimismo, los AG presentan elevada versatilidad y robustez en aplicaciones relacionadas con optimización estructural, manufactura, control industrial, inteligencia artificial y diseño electromagnético. Los enfoques híbridos y adaptativos han incrementado significativamente la estabilidad, precisión y velocidad de convergencia de los algoritmos genéticos modernos, consolidándolos como una de las técnicas metaheurísticas más relevantes dentro de la ingeniería computacional contemporánea.

Finalmente, la evidencia científica analizada demuestra que la efectividad de los algoritmos genéticos depende directamente de la correcta configuración de operadores evolutivos, parámetros de población y estrategias de selección, factores que continúan siendo objeto de investigación activa para mejorar el desempeño en entornos industriales de gran escala. ““

Referencias

- [1] Q. Wang, P. Spronck, and R. Tracht, “An overview of genetic algorithms applied to control engineering problems,” *IEEE Access*, vol. 3, pp. 1651–1655, 2003.
- [2] R. Malhotra *et al.*, “Genetic algorithms: Concepts, design for optimization of process controllers,” *Computer and Information Science*, vol. 4, no. 2, pp. 39–49, 2011.
- [3] A. Slowik and H. Kwasnicka, “Evolutionary algorithms and their applications to engineering problems,” *Neural Computing and Applications*, vol. 32, pp. 12363–12379, 2020.
- [4] X. Yan *et al.*, “Hybrid genetic algorithm for engineering design problems,” *Cluster Computing*, vol. 20, no. 1, pp. 263–275, 2017.
- [5] K. M. Hamdia *et al.*, “An efficient optimization approach for designing machine learning models based on genetic algorithm,” *Neural Computing and Applications*, vol. 33, pp. 1923–1933, 2021.
- [6] T. Küster *et al.*, “Multi-objective optimization of energy-efficient production schedules using genetic algorithms,” *Optimization and Engineering*, vol. 24, pp. 447–468, 2023.
- [7] G. Corriveau *et al.*, “Bayesian network as an adaptive parameter setting approach for genetic algorithms,” *Complex & Intelligent Systems*, vol. 2, pp. 1–22, 2016.
- [8] A. Hussain and Y. S. Muhammad, “Trade-off between exploration and exploitation with genetic algorithm using a novel selection operator,” *Complex & Intelligent Systems*, vol. 6, pp. 1–14, 2020.
- [9] S. D. Dao *et al.*, “An improved genetic algorithm for optimization of production planning and scheduling,” *Journal of Industrial Engineering International*, vol. 13, pp. 143–159, 2017.
- [10] M. Moradgholi *et al.*, “A genetic algorithm for a bi-objective mathematical model for dynamic virtual cell formation problem,” *Journal of Industrial Engineering International*, vol. 12, pp. 343–359, 2016.
- [11] D. E. Goldberg, *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley, 1989.
- [12] M. Srinivas and L. M. Patnaik, “Adaptive probabilities of crossover and mutation in genetic algorithms,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 24, no. 4, pp. 656–667, 1994.
- [13] D. Whitley, “A genetic algorithm tutorial,” *Statistics and Computing*, vol. 4, no. 2, pp. 65–85, 1994.
- [14] K. Deb, *Multi-Objective Optimization Using Evolutionary Algorithms*. John Wiley & Sons, 2001.

- [15] C. A. C. Coello, “Multi-objective optimization by genetic algorithms: A review,” in *Proceedings of the IEEE International Conference on Evolutionary Computation*, pp. 399–404, 1997.
- [16] X. Yan *et al.*, “An improved genetic algorithm and its application,” *TELKOMNIKA*, vol. 10, no. 5, pp. 1081–1086, 2012.
- [17] B. Meniz and F. Tiryaki, “Genetic algorithm optimization with selection operator decider,” *Arabian Journal for Science and Engineering*, vol. 50, pp. 6931–6941, 2025.
- [18] H. Link and D. Weuster-Botz, “Genetic algorithm for multi-objective experimental optimization,” *Bioprocess and Biosystems Engineering*, vol. 29, no. 5–6, pp. 385–390, 2006.
- [19] Q. Li *et al.*, “Multi-objective optimization of parameters design based on genetic algorithm in dual gradient drilling,” *Journal of Petroleum Exploration and Production Technology*, 2024.
- [20] A. Y. Nikravesht *et al.*, “Using genetic algorithms to find optimal solution in a search space for a cloud predictive cost-driven decision maker,” *Journal of Cloud Computing*, vol. 7, no. 20, 2018.